

Independent Evaluation of the PROGOS English Speaking Test

PROGOS 英語スピーキングテストに関する独立評価

Prepared for	Language Services Section internal review
Prepared by	David Dobson
Last revised	2026-07-30
Status	Final Draft For Internal Review



Contents

REPORT / 報告書	1
Independent Evaluation of the PROGOS English Speaking Test	1
PROGOS 英語スピーキングテストに関する独立評価.....	1
1. Executive Summary / エグゼクティブサマリー.....	1
1.1 Purpose / 目的.....	1
1.2 Problem / 課題.....	1
1.3 Method / 方法.....	1
1.4 Results / 結果.....	2
1.5 Recommendations / 提言	3
2. Purpose and Intended Use / 目的および想定される利用	4
2.1 Stated and Inferred Purposes / 明示された目的と推定される目的.....	4
2.2 Scope / 範囲	4
2.3 Evidence Reviewed / 確認した根拠資料.....	5
2.4 Method / 方法.....	5
2.5 Reader Orientation and Terminology / 読者向けの前提説明と用語	5
2.6 Appropriate and Inappropriate Uses / 適切な利用と不適切な利用	6
3. Test Methodology / テスト方法論	8
3.1 Test Overview / テスト概要.....	8
3.2 Task Design and Item-Level Analysis / タスク設計と項目レベルの分析.....	8
3.3 Part 1 - Interview / Part 1 - インタビュー	9
3.4 Part 2 - Reading Aloud / Part 2 - 音読.....	9
3.5 Part 3 - Presentation / Part 3 - プレゼンテーション.....	10
3.6 Part 4 - Graphics Presentation / Part 4 - グラフ説明プレゼンテーション	11
3.7 Part 5 - Communication Activity / Part 5 - コミュニケーション活動	12
3.8 Aozawa 0701 Part 5 misunderstanding / Aozawa 0701 Part 5 における誤解.....	13
3.9 Aozawa 0706 Part 5 clarification / Aozawa 0706 Part 5 における説明.....	13
4. Validity / 妥当性	15
4.1 Construct and Content Validity / 測定概念および内容の妥当性.....	15
4.2 Authenticity / 真正性.....	16
4.3 Interpretive and Consequential Validity / 解釈上および結果影響上の妥当性	16
4.4 Interaction and Reading-Aloud Limitations / インタラクションと音読に関する限界....	17
4.5 Claims Made in Score Reports / スコアレポート内の能力記述.....	17
5. Reliability / 信頼性	18
5.1 Consistency of Test Delivery / テスト実施の一貫性	18

5.2 Scoring Reliability / 採点の信頼性	18
5.3 Aozawa 0701 vs 0706 score comparison / Aozawa 0701 と 0706 のスコア比較	19
5.4 Limitations of the Available Evidence / 利用可能な根拠資料の限界.....	20
5.5 Part 5 and Reliability / Part 5 と信頼性.....	20
6. Test Instructions and Language / テスト指示と使用言語	22
6.1 Language and Clarity of Instructions / 指示の言語と明確性	22
6.2 Cognitive and Listening Demands / 認知的負荷とリスニング負荷	22
6.3 Accessibility and Construct-Irrelevant Variance / アクセシビリティと測定概念外のばらつき	22
7. Fairness and Accessibility / 公平性とアクセシビリティ	24
7.1 Topic Familiarity, Bias, and Access / トピック親近性、バイアス、アクセス.....	24
8. Practicality / 実用性	25
8.1 Cost, Scalability, Delivery, and Reporting Speed / コスト、拡張性、実施、レポート速度.....	25
9. Evaluation of the Score Reports / スコアレポートの評価.....	26
9.1 Report Structure and Descriptor-Alignment Scope / レポート構成とディスクリプター照合の範囲	26
9.2 Category Scores and CEFR Workbook Comparison / カテゴリースコアと CEFR ワークブックの比較	27
9.3 CEFR-J Descriptor Comparison / CEFR-J ディスクリプター比較.....	28
9.4 Overall Assessment Comments / Overall Assessment コメント	30
9.5 Diagnostic Usefulness, Individualisation, and Templating / 診断上の有用性、個別化、テンプレート性	31
9.6 Transparency of Score Interpretation / スコア解釈の透明性	32
10. Legal and Ethical Considerations / 法務上および倫理上の考慮事項.....	34
10.1 Privacy, Terms of Use, and Voice Recordings / プライバシー、利用規約、音声録音 ..	34
10.2 AI Governance and Transparency Gaps / AI ガバナンスと透明性の不足.....	35
11. Suitability for the Organisation's Purposes / 組織の目的に対する適合性	37
11.1 Pre/Post Testing and Score-Change Interpretation / 事前・事後テストとスコア変化の解釈	37
12. Conclusions and Recommendations / 結論と提言.....	39
12.1 Summary of Findings / 所見の要約.....	39
12.2 Limitations / 限界.....	40
12.3 Recommendations / 提言	40

1. Executive Summary / エグゼクティブサマリー

1.1 Purpose / 目的

This report evaluates whether PROGOS is suitable for Language Services Section use as an English speaking test, a score-reporting system, and a possible source of evidence for placement, progress measurement, course design, teacher assignment, and learner diagnosis.

本報告書は、PROGOS がランゲージサービス課において、英語スピーキングテスト、スコアレポートシステム、およびクラス分け、進捗測定、コース設計、講師割り当て、学習者診断のための根拠資料として適しているかを評価するものである。

1.2 Problem / 課題

PROGOS is practically attractive because it is short, standardised, automated, and externally reported. The section needs to know whether those practical advantages are strong enough to support local decisions about learners. The main risk is that a convenient broad benchmark may be mistaken for a sufficiently detailed placement, progress-measurement, course-design, teacher-assignment, or diagnostic tool.

PROGOS は、短時間で実施でき、標準化され、自動化され、外部からレポートが提供されるため、実務上は魅力的である。当課としては、こうした実用上の利点が、学習者に関する内部判断を支えるだけの強さを持つかを確認する必要がある。主なリスクは、便利な広範囲のベンチマークが、詳細なクラス分け、進捗測定、コース設計、講師割り当て、または診断ツールとして十分であると誤って受け取られることである。

1.3 Method / 方法

The review used three PROGOS score reports: two tests taken by Aozawa on 2026-07-01 and 2026-07-06, plus one test taken by Saki on 2026-06-30. For the two Aozawa tests, an observer was present to record the speaking test and question prompts. The review therefore also used task screenshots and audio evidence from both Aozawa tests, making it possible to compare reported scores with observed performance. The score-report comments were checked against both CEFR and CEFR-J descriptors because PROGOS public materials refer to both frameworks without clearly stating which one governs each report comment. Public PROGOS legal and

本レビューでは、3 件の PROGOS スコアレポートを使用した。2026-07-01 および 2026-07-06 に Aozawa が受験した 2 件と、2026-06-30 に Saki が受験した 1 件である。Aozawa の 2 回のテストでは、スピーキングテストと設問プロンプトを記録するために観察者が同席した。そのため、本レビューでは Aozawa の両テストのタスク画面および音声記録も使用し、報告されたスコアと観察されたパフォーマンスを比較できるようにした。PROGOSの公開資料ではCEFRとCEFR-Jの両方に言及しているが、各レポートコメントがどちらに基づくものかを明確に示していないため、スコアレポートのコメントは CEFR および CEFR-J の両方のディスクリプターと照合した。また、運用、デ

policy pages were also reviewed for operational, data-handling, and transparency points.

一タ取扱い、透明性に関する観点から、PROGOS の公開されている法務・ポリシーページも確認した。

1.4 Results / 結果

PROGOS appears usable as a broad external speaking benchmark, but the available evidence does not support using it as the main basis for fine-grained local decisions. The strongest observed evidence concerns spoken production: short answers, read-aloud performance, prepared presentation, and timed responses. However, the Communication Activity uses fixed prerecorded prompts, so it does not directly show live workplace interaction, clarification, repair, turn management, or adaptive response to a real interlocutor.

Part 4 also creates an important design concern. The task asks the learner to understand a graph, select and interpret the key information, and explain it orally. In CEFR Companion Volume terms, this is a mediation activity, specifically "Explaining data". In the three reviewed score reports, the result is presented through speaking-quality categories rather than through a separate mediation category, so one of the central abilities required by Part 4 is not transparently assessed or reported.

The two Aozawa tests show score-interpretation risk. Over five days, Aozawa's overall level moved from "A2 High" on 2026-07-01 to "B1 High" on 2026-07-06, with several category sub scores also changing. The test content was not identical, Part 5 changed, and the 2026-07-06 test included clarification from the observer during the Part 5 preparation period. This comparison should therefore be read as evidence of comparability risk, not as proof of short-term improvement.

PROGOS は、広範囲の外部スピーキングベンチマークとしては利用可能と思われるが、利用可能な根拠資料は、詳細な内部判断の主要な根拠として用いることを支持していない。観察された最も強い根拠は、短い回答、音読、準備を伴うプレゼンテーション、制限時間内の応答といったスピーキング産出に関するものである。一方、Communication Activity は固定された事前録音プロンプトを用いるため、実際の職場でのやり取り、確認、修復、ターン管理、実在の相手への適応的な応答を直接示すものではない。

Part 4 にも重要な設計上の懸念がある。このタスクでは、学習者がグラフを理解し、重要な情報を選択・解釈し、それを口頭で説明することが求められる。CEFR Companion Volume の用語では、これは媒介活動、具体的には「データを説明する」活動である。確認した 3 件のスコアレポートでは、結果は独立した媒介カテゴリーではなくスピーキング品質のカテゴリーを通して提示されている。そのため、Part 4 が求める中心的能力の一つが、透明な形で評価または報告されていない。

Aozawa の 2 回のテストは、スコア解釈上のリスクを示している。5 日間で、Aozawa の総合レベルは 2026-07-01 の「A2 High」から 2026-07-06 の「B1 High」へ移動し、複数のカテゴリーサブスコアも変化した。テスト内容は同一ではなく、Part 5 も変更され、2026-07-06 のテストでは Part 5 の準備時間中に観察者による説明が入った。したがって、この比較は短期間の向上の証拠ではなく、比較可能性に関するリスクの証拠として読むべきである。

The score reports are readable and motivating, but their diagnostic value is limited. They do not quote the learner's own responses, do not explain how observed responses led to ratings, and do not flag major task-level problems. In Aozawa's 2026-07-01 test, he misunderstood the Part 5 role and repeatedly answered as an employer or recruiter rather than advising a job applicant. The report did not identify that issue.

スコアレポートは読みやすく、学習者の動機づけにつながる可能性があるが、診断上の価値は限定的である。学習者本人の回答を引用せず、観察された回答がどのように評価につながったかを説明せず、タスクレベルの重大な問題を示さない。Aozawa の 2026-07-01 のテストでは、本人が Part 5 の役割を誤解し、就職面接を受ける人に助言するのではなく、雇用主または採用担当者として繰り返し回答した。レポートはこの問題を指摘していなかった。

1.5 Recommendations / 提言

Use PROGOS only as supplementary external evidence for broad benchmarking. Do not use it as the main basis for fine-grained placement, short-cycle pre/post progress measurement, course design, teacher assignment, or individual diagnostic planning.

If broader local use is considered, first request evidence from PROGOS on reliability, score-change interpretation, measurement error, equivalence between test versions, scoring methods, category-score aggregation, human review, and AI governance. Any local pilot should compare PROGOS results with the section's current assessment decisions and independent human ratings.

PROGOS は、広範囲のベンチマークのための補助的な外部根拠としてのみ使用するべきである。詳細なクラス分け、短期間の事前・事後進捗測定、コース設計、講師割り当て、または個別診断計画の主要な根拠として使用するべきではない。

より広い内部利用を検討する場合は、信頼性、スコア変化の解釈、測定誤差、テストバージョン間の等価性、採点方法、カテゴリースコアの重みづけ・集計方法、人間による確認、AI ガバナンスに関する根拠資料を、まず PROGOS に求めるべきである。内部パイロットを実施する場合は、PROGOS の結果を当課の現在の評価判断および独立した人間による評価と比較する必要がある。

2. Purpose and Intended Use / 目的および想定される利用

2.1 Stated and Inferred Purposes / 明示された目的と推定される目的

The three reviewed score reports present PROGOS as a business English speaking test that reports:

- a CEFR-aligned overall level
- six category-level ratings
- learner-facing feedback and study advice

The user-policy page states that PROGOS uses automated voice delivery and scores results according to the company's own criteria.

確認した 3 件のスコアレポートでは、PROGOS は次の項目を報告するビジネス英語スピーキングテストとして提示されている。

- CEFR に準拠した総合レベル
- 6 つのカテゴリー別評価
- 学習者向けのフィードバックおよび学習アドバイス

ユーザーポリシーページでは、PROGOS が自動音声による出題を用い、同社独自の評価基準に従って結果を採点すると記載されている。

2.2 Scope / 範囲

This review evaluates the evidence available to the section: the observed score reports, screenshots and audio evidence for the two Aozawa tests, CEFR and CEFR-J descriptor resources, and captured public PROGOS legal pages. The conclusions in this report are limited to that evidence set.

The named test takers, Aozawa and Saki, are the people represented in the reviewed internal evidence set. Their names are retained here because the reviewed score reports identify them. Before wider circulation, the section should make a deliberate decision on whether named individual performance details should be anonymised.

The observer clarified the Part 5 scenario during Aozawa's 2026-07-06 test. That clarification is treated as important evidence because it affects comparability with a test completed without outside help.

本レビューは、当課が利用できる根拠資料、すなわち確認したスコアレポート、Aozawa の 2 回のテストに関するスクリーンショットおよび音声記録、CEFR および CEFR-J のディスクリプター資料、保存された PROGOS の公開法務ページを評価するものである。本報告書の結論は、この根拠資料の範囲に限定される。

Aozawa および Saki は、確認した内部根拠資料に含まれる受験者である。確認したスコアレポートに氏名が記載されているため、本報告書でも氏名を保持している。より広い範囲で共有する前に、個人のパフォーマンス情報を匿名化すべきかについて、当課として明確に判断する必要がある。

観察者は、Aozawa の 2026-07-06 のテスト中に Part 5 のシナリオを説明した。この説明は、外部支援なしで完了したテストとの比較可能性に影響するため、重要な根拠として扱う。

2.3 Evidence Reviewed / 確認した根拠資料

The review used:

- three PROGOS score reports: Aozawa 2026-07-01, Aozawa 2026-07-06, and Saki 2026-06-30
- task screenshots and audio evidence for both Aozawa tests
- CEFR descriptor resources and the CEFR Companion Volume
- CEFR-J descriptor resources
- public PROGOS legal and policy pages captured on 2026-07-03

本レビューでは、次の資料を使用した。

- 3 件の PROGOS スコアレポート：Aozawa 2026-07-01、Aozawa 2026-07-06、Saki 2026-06-30
- Aozawa の両テストに関するタスク画面および音声記録
- CEFR ディスクリプター資料および CEFR Companion Volume
- CEFR-J ディスクリプター資料
- 2026-07-03 に保存した PROGOS の公開法務・ポリシーページ

2.4 Method / 方法

The report separates:

- direct observation from test materials, transcripts, reports, workbook descriptors, and legal pages
- inference grounded in those materials
- explicit limitations where the evidence does not support a stronger conclusion

Where a PROGOS position matters, the report cites the relevant reviewed public document directly.

本報告書では、次のものを区別する。

- テスト資料、文字起こし、レポート、ワークブックのディスクリプター、法務ページからの直接観察
- それらの資料に基づく推論
- 根拠資料がより強い結論を支えない場合の明示的な限界

PROGOS 側の立場が重要になる箇所では、本報告書は確認済みの関連公開文書を直接参照する。

2.5 Reader Orientation and Terminology / 読者向けの前提説明と用語

CEFR means the Common European Framework of Reference for Languages. CEFR-J refers to the CEFR-Japan framework, which adapts CEFR levels and descriptors for English-language learning in Japan, including finer sublevels such as A2.2 and B1.2.

In the three reviewed score reports, the result page gives an overall CEFR-style level and a category section labelled 指標別評価

CEFR は Common European Framework of Reference for Languages を指す。CEFR-J は CEFR-Japan フレームワークを指し、日本における英語学習に合わせて CEFR レベルとディスクリプターを調整したもので、A2.2 や B1.2 など、より細かい下位レベルを含む。

確認した 3 件のスコアレポートでは、結果ページに CEFR 形式の総合レベルと、指標別評価と表示されたカテゴリー欄がある。この欄には、6 つのカテゴリー別評価が含まれる。

. That section contains six category-level ratings:

- Range: breadth and flexibility of language repertoire
- Accuracy: grammatical control and correctness
- Fluency: flow, pausing, repair, and continuity of speech
- Interaction: ability to respond to or manage communicative exchange
- Coherence: organisation, linking, and clarity across connected speech
- Phonology: pronunciation, stress, rhythm, and intelligibility

PROGOS also uses finer labels such as "A2 High", "B1 High", and "B2 and above". These are PROGOS reporting labels layered onto the CEFR scale; the reviewed public materials do not define the cut scores, measurement error, or minimum meaningful change for those labels.

Mediation is treated in the CEFR Companion Volume as a communicative language activity alongside reception, production, and interaction. This matters for Part 4 because explaining graph data in speech is not only spoken production; it also involves understanding visually organised information and transforming it into verbal text.

- Range：言語レパートリーの幅と柔軟性
- Accuracy：文法のコントロールと正確さ
- Fluency：発話の流れ、ポーズ、修復、継続性
- Interaction：コミュニケーション上のやり取りに応答または管理する能力
- Coherence：まとまりのある発話における構成、つながり、明確さ
- Phonology：発音、強勢、リズム、聞き取りやすさ

PROGOS は、「A2 High」、「B1 High」、「B2 and above」などのより細かいラベルも使用している。これらは CEFR スケールに重ねられた PROGOS 独自の報告ラベルであり、確認した公開資料では、そのカットスコア、測定誤差、または意味のある最小変化は定義されていない。

CEFR Companion Volume では、Mediation は Reception、Production、Interaction と並ぶコミュニケーション言語活動として扱われる。これは Part 4 に関係する。グラフデータを口頭で説明することは単なるスピーキング産出ではなく、視覚的に整理された情報を理解し、それを言語テキストに変換することも含むためである。

2.6 Appropriate and Inappropriate Uses / 適切な利用と不適切な利用

The evidence supports only cautious, supplementary use. PROGOS may be useful as a broad external benchmark, especially where the organisation needs a quick standardised speaking indicator. It should not be used as the primary basis for fine placement, short-cycle pre/post progress claims, course design, teacher assignment, or individual diagnostic planning unless stronger validation, reliability,

根拠資料が支持するのは、慎重な補助的利用に限られる。PROGOS は、特に組織が迅速で標準化されたスピーキング指標を必要とする場合、広範囲の外部ベンチマークとして有用である可能性がある。しかし、より強い妥当性、信頼性、スコア変化、スコア解釈の根拠が得られない限り、詳細なクラス分け、短期間の事前・事後進捗主張、コース設計、講師割り当て、個別診断計画の主要な根拠として使用すべきではない。

score-change, and score-interpretation evidence is obtained.

3. Test Methodology / テスト方法論

3.1 Test Overview / テスト概要

The observed test parts are:

1. Interview
2. Reading Aloud
3. Presentation
4. Graphics Presentation
5. Communication Activity

Observed timing:

観察されたテストパートは次のとおりである。

1. インタビュー
2. 音読
3. プレゼンテーション
4. グラフ説明プレゼンテーション
5. コミュニケーション活動

観察された時間配分は次のとおりである。

Part	Observed format	Timing
Part 1 - Interview	10 audio questions	20 seconds speaking time per question
Part 2 - Reading Aloud	8 displayed sentences	10 seconds per sentence
Part 3 - Presentation	one topic prompt	40 seconds preparation, 60 seconds speaking
Part 4 - Graphics Presentation	graph description	40 seconds preparation, 60 seconds speaking
Part 5 - Communication Activity	scenario plus four fixed audio prompts	40 seconds preparation, then 30 seconds after each prompt

3.2 Task Design and Item-Level Analysis / タスク設計と項目レベルの分析

The five-part design mixes short prompted answers, read-aloud performance, a short prepared presentation, graph explanation, and simulated responses to spoken prompts. The evaluation below explains what each part usefully shows and where the task design may make score interpretation harder.

5 部構成の設計は、短いプロンプトへの回答、音読、短い準備付きプレゼンテーション、グラフ説明、音声プロンプトへの模擬応答を組み合わせている。以下の評価では、各パートが何を有効に示すか、またタスク設計がどこでスコア解釈を難しくする可能性があるかを説明する。

3.3 Part 1 - Interview / Part 1 - インタビュー

Part 1 elicits short spontaneous responses across familiar and workplace-related topics. It is useful for sampling short-answer production under time pressure.

The Interview part uses fixed audio questions. The speaker does not react, clarify, or follow up.

The first Aozawa test included some wording concerns. The clearest example is "How do you imagine your company this time next year?", which is understandable but under-specified and non-idiomatic. A more natural version would be "What do you imagine your company will be like this time next year?"

The second Aozawa test used different Part 1 questions, including household, manager, customer, sales, dismissal, employee-retention, and health-care questions. The content therefore changed materially between the two tests.

Part 1 は、身近な話題および職場関連の話題について、短い即興回答を引き出す。制限時間内での短答型スピーキング産出をサンプリングするうえで有用である。

Interview パートでは、固定された音声質問を用いる。話者は受験者の発話に反応せず、確認も追加質問もしない。

Aozawa の1回目のテストには、いくつか表現上の懸念があった。最も明確な例は「How do you imagine your company this time next year?」で、理解は可能だが、指定が不十分で自然な英語表現ではない。より自然な表現は「What do you imagine your company will be like this time next year?」である。

Aozawa の2回目のテストでは、家庭、マネージャー、顧客、営業、解雇、従業員定着、医療に関する質問など、異なる Part 1 の質問が用いられた。そのため、2回のテスト間で内容は実質的に変化している。

3.4 Part 2 - Reading Aloud / Part 2 - 音読

Part 2 gives controlled evidence of:

- decoding
- pronunciation
- stress and rhythm
- sentence-level fluency

It gives little direct evidence of Range, Coherence, or Interaction because the learner is reading fixed text rather than generating language.

The first Aozawa test contained several wording concerns, including "request for changes", "shift our production to somewhere in Southeast Asia", "Information Tech company", and the contextually odd "their existing products ... on Thursday".

Part 2 は、次の点について統制された根拠を与える。

- 文字から音へのデコード
- 発音
- 強勢とリズム
- 文レベルの流暢さ

学習者は言語を自分で生成するのではなく固定されたテキストを読むため、Range、Coherence、Interaction に関する直接的な根拠は限定的である。

Aozawa の1回目のテストには、「request for changes」、「shift our production to somewhere in Southeast Asia」、「Information Tech company」、文脈上不自然な「their existing products ... on Thursday」

The second test also contained variable lexical and syntactic demands. Examples include:

- "An advantageous career move is what you need, don't you think?"
- "So, what's stopping them from making a decision and pursuing these options?"
- "She's focusing too much on what she's getting out of this networking event."

Those sentences may be valid read-aloud material, but they are not equal in difficulty to simple workplace sentences. Without item-calibration evidence, this variation remains an interpretation risk.

など、複数の表現上の懸念が含まれていた。

2 回目のテストにも、語彙および構文上の要求のばらつきが含まれていた。例は次のとおりである。

- 「必要なのは、有利なキャリア上の一手だと思いませんか。」
- 「では、彼らが決定を下してこれらの選択肢を進めるのを妨げているものは何でしょうか。」
- 「彼女は、このネットワーキングイベントから自分が何を得られるかに意識を向け過ぎている。」

これらの文は音読素材として妥当かもしれないが、単純な職場文と同じ難度ではない。項目較正に関する根拠がなければ、このばらつきは解釈上のリスクとして残る。

3.5 Part 3 - Presentation / Part 3 - プレゼンテーション

Part 3 is a strong task for sustained production. It gives useful evidence for:

- Range
- Accuracy
- Fluency
- Coherence
- topic development

The two Aozawa tests used related but not identical prompts:

Part 3 は、持続的なスピーキング産出を測る強いタスクである。次の点について有用な根拠を与える。

- 言語範囲
- 正確さ
- 流暢さ
- 一貫性
- トピック展開

Aozawa の 2 回のテストでは、関連しているが同一ではないプロンプトが用いられた。

Date	Prompt
2026-07-01	Talk about the best colleague you ever worked with.
2026-07-06	Talk about the best company you worked for.

Both are workplace-relevant. They may favour learners with work experience and may be less suitable for learners without professional experience unless alternative

どちらも職場に関連する内容である。仕事経験のある学習者に有利に働く可能性があり、学習や地域活動の例を代替として認め

study or community examples are allowed.

ない場合、職業経験のない学習者には適さない可能性がある。

3.6 Part 4 - Graphics Presentation / Part 4 - グラフ説明プレゼンテーション

Part 4 is one of the most business-relevant tasks in PROGOS because it asks the learner to explain a graph. This is a common workplace communication activity: people often need to describe trends, compare quantities, select the most important information, and give a concise spoken explanation.

That strength also creates an assessment problem. Part 4 is not simply a speaking task. Before speaking, the learner has to read the graph, understand the labels and numbers, decide what information matters, interpret the trend or comparison, and then explain that interpretation in spoken English under time pressure. Only the final stage is speaking in the narrow sense.

The CEFR Companion Volume treats this kind of graph explanation as mediation, not just production. Table 3 places "Mediating a text" under Mediation as a communicative language activity, separate from Production and Interaction. The Companion Volume's "Explaining data" scale then covers the transformation of information in graphs, charts, diagrams, and similar visuals into spoken or written text.

None of the three reviewed score reports includes Mediation as a separate result category. Part 4 therefore appears to be represented through the same speaking-quality categories used elsewhere: Range, Accuracy, Fluency, Coherence, Phonology, and Interaction. Those categories can describe the spoken output, but they do not separately show whether the learner understood the graph, chose the right infor-

Part 4 は、学習者にグラフを説明させるため、PROGOS の中で最もビジネス関連性の高いタスクの一つである。これは一般的な職場コミュニケーション活動であり、人は傾向を説明し、数量を比較し、最も重要な情報を選び、簡潔に口頭説明する必要がある。

この強みは同時に評価上の問題も生む。Part 4 は単純なスピーキングタスクではない。話す前に、学習者はグラフを読み、ラベルや数値を理解し、どの情報が重要かを判断し、傾向または比較を解釈し、その解釈を制限時間内に英語で口頭説明しなければならない。狭い意味でスピーキングと言えるのは最後の段階だけである。

CEFR Companion Volume では、この種のグラフ説明は単なる Production ではなく Mediation として扱われる。Table 3 では、「Mediating a text」が Production や Interaction とは別のコミュニケーション言語活動として Mediation の下に置かれている。さらに Companion Volume の「Explaining data」スケールは、グラフ、チャート、図表、類似の視覚資料に含まれる情報を、話し言葉または書き言葉に変換する活動を扱っている。

確認した 3 件のスコアレポートのいずれにも、Mediation は独立した結果カテゴリーとして含まれていない。そのため Part 4 は、他の箇所と同じスピーキング品質カテゴリー、すなわち Range、Accuracy、Fluency、Coherence、Phonology、Interaction を通して表現されているように見える。これらのカテゴリーは発話結果を記述できるが、学習者がグラフを理解したか、適切な情報を選んだか、正確に解釈した

mation, interpreted it accurately, or successfully mediated visual information for another person.

This matters for section use. If PROGOS is used only as a broad external speaking benchmark, this limitation may be acceptable. If it is used for diagnosis, course design, placement, or progress measurement, Part 4 is under-accounted for: the task requires a central mediation ability, but the report does not make that ability visible in the scoring or feedback.

The two Aozawa tests used different graph tasks:

か、他者のために視覚情報をうまく媒介したかを個別には示さない。

これは当課での利用に関わる。PROGOS を広範囲の外部スピーキングベンチマークとしてのみ用いるなら、この限界は許容できるかもしれない。しかし、診断、コース設計、クラス分け、進捗測定に用いる場合、Part 4 は十分に説明されていない。タスクは中心的な媒介能力を必要とするが、レポートはその能力を採点やフィードバックの中で可視化していない。

Aozawa の2回のテストでは、異なるグラフタスクが用いられた。

Date	Topic
2026-07-01	advertising-industry revenue in Country A and Country B, 2013-2017
2026-07-06	annual passengers using metro systems in Country G and Country H, 2014-2018

The task type is stable, but the content is not identical. This limits direct comparison between the two results.

タスクタイプは安定しているが、内容は同一ではない。このため、2つの結果を直接比較することには限界がある。

3.7 Part 5 - Communication Activity / Part 5 - コミュニケーション活動

Part 5 is the main construct-validity concern.

The topic and communicative functions are realistic, but the format is not live interaction. The learner hears fixed prerecorded prompts and responds into fixed time windows. The learner cannot:

- negotiate meaning
- ask for clarification and receive a contingent answer
- repair a shared misunderstanding
- manage turns
- initiate a topic

Part 5 は、測定概念の妥当性に関する主な懸念点である。

話題とコミュニケーション機能は現実的であるが、形式はライブのやり取りではない。学習者は固定された事前録音プロンプトを聞き、固定された時間枠内で回答する。学習者は次のことができない。

- 意味を交渉する
- 確認を求め、相手の回答に応じた返答を受ける
- 共有された誤解を修復する
- ターンを管理する
- 話題を開始する

- influence the direction of the exchange

Therefore, Part 5 supports evidence about prompted responses in a simulated conversation. It does not strongly support CEFR-style oral interaction as a co-constructed activity.

- やり取りの方向性に影響を与える

したがって、Part 5 は模擬会話におけるプロンプト応答に関する根拠を提供する。一方で、共同構築される活動としての CEFR 型の口頭インタラクションを強く支持するものではない。

3.8 Aozawa 0701 Part 5 misunderstanding / Aozawa 0701 Part 5 における誤解

In the 2026-07-01 test, Part 5 was about advising someone preparing for a job interview. Aozawa persistently answered as if he were an employer or recruiter:

- he described "my company" and its departments rather than documents to bring
- he discussed workplace dress rules and his own T-shirt rather than interview clothing
- he answered salary and holiday questions as employment-policy questions rather than as interview-advice questions
- he invited the speaker to apply and contact him

The issue extended across all four prompts. It was a role/scenario misunderstanding that confounds interpretation of the intended Communication Activity.

2026-07-01 のテストでは、Part 5 は就職面接の準備をしている人に助言する内容であった。Aozawa は一貫して、自分が雇用主または採用担当者であるかのように回答した。

- 持参すべき書類ではなく、「my company」とその部署について説明した
- 面接時の服装ではなく、職場の服装規則と自分の T シャツについて話した
- 給与や休暇に関する質問を、面接助言ではなく雇用方針に関する質問として回答した
- 相手に応募し、自分に連絡するよう促した

この問題は 4 つすべてのプロンプトに及んだ。これは、意図された Communication Activity の解釈を混乱させる役割・シナリオの誤解であった。

3.9 Aozawa 0706 Part 5 clarification / Aozawa 0706 Part 5 における説明

In the 2026-07-06 test, Part 5 was about employee training. During the preparation period, the observer clarified possible interpretations of "training attended". This is direct evidence that the test was not completed under fully standard conditions.

The clarification likely helped explain the scenario, and Aozawa then responded more directly to the prompts. That is use-

2026-07-06 のテストでは、Part 5 は従業員研修に関する内容であった。準備時間中に、観察者は「training attended」の解釈の可能性を説明した。これは、テストが完全に標準的な条件下で完了しなかったことを示す直接的な根拠である。

その説明はシナリオ理解を助けた可能性が高く、その後 Aozawa はプロンプトにより直接的に回答した。これはタスク理解の役

ful evidence about the role of task comprehension, but it limits comparability with a test completed without outside help.

The contrast between the two tests supports a key conclusion: Part 5 performance can be materially affected by task and role comprehension. If the intended construct is spoken production, clearer task setup or L1 support would reduce irrelevant difficulty. If the intended construct includes English-only comprehension of task instructions, then the report should make that interpretation explicit.

割に関する有用な根拠であるが、外部支援なしで完了したテストとの比較可能性を制限する。

2回のテストの対照は、重要な結論を支持する。Part 5 のパフォーマンスは、タスクと役割の理解によって実質的に影響を受ける可能性がある。意図された測定概念がスピーキング産出であるなら、より明確なタスク設定または L1 サポートにより、無関係な難しさを減らせるだろう。意図された測定概念に英語のみでのタスク指示理解が含まれるなら、レポートはその解釈を明示すべきである。

4. Validity / 妥当性

Validity concerns whether a test supports the decisions people want to make from its results. For PROGOS, the key question is not simply whether the test is well designed in general, but whether its task design, scoring categories, and score-report claims support Language Services Section uses such as placement, progress measurement, course design, teacher assignment, and learner diagnosis. In test-methodology terms, this means checking whether the test actually elicits the abilities it reports, whether the tasks match the target business-English use, and whether the reported scores can be interpreted in the way local users are likely to interpret them.

妥当性とは、テスト結果から人々が行いたい判断を、そのテストがどの程度支えられるかに関するものである。PROGOS についての中心的な問いは、単にテスト全体の設計がよいかどうかではなく、そのタスク設計、採点カテゴリー、スコアレポート上の能力記述が、クラス分け、進捗測定、コース設計、講師割り当て、学習者診断といったランゲージサービス課の利用目的を支えるかである。テスト方法論の用語では、これはテストが報告している能力を実際に引き出しているか、タスクが対象とするビジネス英語使用場面と合っているか、報告されたスコアを現場の利用者が解釈しそうな方法で解釈できるかを確認することを意味する。

4.1 Construct and Content Validity / 測定概念および内容の妥当性

The task mix gives useful evidence of several abilities that matter in business English: answering short prompts, reading aloud clearly, giving a short prepared presentation, explaining visual information, and responding under time pressure.

However, PROGOS gives weak evidence for live interaction. The reviewed test tasks do not show whether a learner can ask for clarification, repair a misunderstanding with another person, manage turns, initiate or redirect a conversation, or adapt to an unpredictable interlocutor. This matters because Interaction appears as one of the six category-level ratings in the three reviewed score reports, but the reviewed test format does not directly test interaction in the ordinary workplace sense.

タスクの組み合わせは、ビジネス英語で重要となる複数の能力、すなわち短いプロンプトへの回答、明瞭な音読、短い準備付きプレゼンテーション、視覚情報の説明、制限時間内での応答について有用な根拠を与える。

しかし、PROGOS がライブインタラクションについて与える根拠は弱い。確認したテストタスクは、学習者が確認を求める、他者との誤解を修復する、ターンを管理する、会話を開始または方向転換する、予測できない相手に適応する、といったことができるかを示さない。この点は重要である。Interaction は確認した 3 件のスコアレポートで 6 つのカテゴリー別評価の一つとして表示されているが、確認したテスト形式は通常の職場での意味におけるインタラクションを直接テストしていない。

4.2 Authenticity / 真正性

The test includes several business-relevant speaking activities: short prompted answers, workplace presentation, graph description, and advice or recommendation responses. Part 4 is especially authentic for business English because it requires describing trends, comparing quantities, and selecting relevant information under time pressure.

That authenticity does not make Part 4 a simple speaking-production task. In CEFR Companion Volume terms, explaining graph or chart data in speech is better understood as "Mediating a text", specifically "Explaining data". The learner interprets visually organised information and turns it into spoken language for another person. Because the three reviewed score reports do not include a mediation result category, the score report does not separately account for graph comprehension, information selection, interpretation, or successful explanation of the visual information. For local use, that is a design concern: a mediation task is being reported through a speaking-score profile without making the mediation performance visible.

Authenticity is weaker for interaction. Part 5 resembles a communicative exchange, but it remains a fixed-prompt simulation rather than a live conversation. The learner cannot ask for clarification and receive a contingent reply, repair shared misunderstanding, negotiate meaning, or influence the direction of the exchange.

このテストには、短いプロンプトへの回答、職場プレゼンテーション、グラフ説明、助言または提案への応答など、ビジネスに関連する複数のスピーキング活動が含まれている。Part 4 は、傾向を説明し、数量を比較し、制限時間内で関連情報を選択することを求めるため、ビジネス英語として特に真正性が高い。

ただし、その真正性は Part 4 を単純なスピーキング産出タスクにするものではない。CEFR Companion Volume の用語では、グラフやチャートのデータを口頭で説明することは、「Mediating a text」、具体的には「Explaining data」と理解する方が適切である。学習者は視覚的に整理された情報を解釈し、それを他者に向けた話し言葉に変換する。確認した 3 件のスコアレポートには媒介の結果カテゴリーが含まれていないため、スコアレポートは、グラフ理解、情報選択、解釈、視覚情報の適切な説明を個別には扱っていない。内部利用において、これは設計上の懸念である。媒介タスクが、媒介パフォーマンスを可視化しないままスピーキングスコアプロフィールとして報告されているためである。

インタラクションに関する真正性はより弱い。Part 5 はコミュニケーション上のやり取りに似ているが、ライブ会話ではなく固定プロンプトによるシミュレーションのままである。学習者は、確認を求めて相手の回答に応じた返答を受ける、共有された誤解を修復する、意味を交渉する、やり取りの方向性に影響を与える、といったことができない。

4.3 Interpretive and Consequential Validity / 解釈上および結果影響上の妥当性

The available evidence does not show how task performance is converted into category ratings or an overall level. That limits

利用可能な根拠資料は、タスクでのパフォーマンスがどのようにカテゴリー評価または総合レベルに変換されるかを示していない

interpretation, especially when the score reports make broad "You can" statements without showing the learner responses that support those claims.

Consequential validity is also limited by the likely organisational uses. Broad benchmarking is a low-risk supplementary use. Fine placement, progress measurement, course design, teacher assignment, and individual diagnosis require more stable and more transparent score interpretation than the reviewed evidence provides.

い。特にスコアレポートが、根拠となる学習者の回答を示さずに広い「You can」記述を行う場合、このことは解釈を制限する。

結果影響上の妥当性も、想定される組織内利用によって制限される。広範囲のベンチマークはリスクの低い補助的利用である。詳細なクラス分け、進捗測定、コース設計、講師割り当て、個別診断には、確認した根拠資料が示すよりも安定的で透明性の高いスコア解釈が必要である。

4.4 Interaction and Reading-Aloud Limitations / インタラクションと音読に関する限界

Interaction appears as one of the six category-level ratings in the reviewed score reports, but the observed test does not directly test live interaction. Reading Aloud gives controlled evidence about pronunciation, stress, rhythm, decoding, and sentence-level fluency, but it gives limited evidence about Range, Coherence, or Interaction because the learner is reading fixed text rather than generating language.

Interaction は確認したスコアレポートで 6 つのカテゴリー別評価の一つとして表示されているが、観察されたテストはライブインタラクションを直接テストしていない。Reading Aloud は、発音、強勢、リズム、デコード、文レベルの流暢さについて統制された根拠を与えるが、学習者が言語を生成するのではなく固定テキストを読んでいるため、Range、Coherence、Interaction に関する根拠は限定的である。

4.5 Claims Made in Score Reports / スコアレポート内の能力記述

The score reports make broad ability claims through the Overall Assessment and category comments. Those claims are evaluated in detail in the later score-report section because their alignment depends on both CEFR and CEFR-J descriptor checks and on whether the comments are sufficiently tied to observed learner performance.

スコアレポートは、Overall Assessment およびカテゴリーコメントを通して広い能力記述を行っている。これらの記述については、CEFR および CEFR-J の両方のディスクリプター照合と、コメントが観察された学習者パフォーマンスに十分結びついているかに依存するため、後半のスコアレポートセクションで詳しく評価する。

5. Reliability / 信頼性

Reliability concerns how consistently a test produces results. For PROGOS, the practical question is whether a score, subscore, or reported level would remain stable enough to support local decisions if the learner took a different version of the test, repeated the test after a short interval, or encountered slightly different task content. In test-methodology terms, this means checking delivery consistency, score stability, equivalence between test versions, measurement error, and the transparency of how task performances become category ratings and an overall level.

信頼性とは、テストがどの程度一貫して結果を出すかに関するものである。PROGOS についての実務上の問いは、学習者が別のバージョンのテストを受けた場合、短期間後に再受験した場合、または少し異なるタスク内容に当たった場合でも、そのスコア、サブスコア、または報告レベルが内部判断を支えるだけ安定しているかである。テスト方法論の用語では、これは実施の一貫性、スコアの安定性、テストバージョン間の等価性、測定誤差、タスクパフォーマンスがどのようにカテゴリー評価と総合レベルになるかの透明性を確認することを意味する。

5.1 Consistency of Test Delivery / テスト実施の一貫性

The observed design supports consistent delivery in several respects:

- fixed prompts
- fixed timings
- automated audio delivery
- standard report format
- repeatable task structure across tests

Those features support standardisation. They do not establish score reliability.

観察された設計は、複数の点で一貫した実施を支えている。

- 固定プロンプト
- 固定時間
- 自動音声による出題
- 標準的なレポート形式
- テスト間で反復可能なタスク構造

これらの特徴は標準化を支える。しかし、スコアの信頼性を確立するものではない。

5.2 Scoring Reliability / 採点の信頼性

The available evidence does not show:

- how stable results are when a learner retakes the test
- whether different test versions are equivalent in difficulty
- measurement error
- classification consistency
- subscore reliability

利用可能な根拠資料は、次の点を示していない。

- 学習者が再受験した場合に結果がどの程度安定するか
- 異なるテストバージョンの難度が等価であるか
- 測定誤差
- 分類の一貫性

- agreement between automated scores and qualified human ratings
- how category ratings are weighted or aggregated
- how the overall level is derived from the six category ratings
- サブスコアの信頼性
- 自動採点と有資格の人間による評価の一致度
- カテゴリー評価がどのように重みづけまたは集計されるか
- 総合レベルが6つのカテゴリー評価からどのように算出されるか

5.3 Aozawa 0701 vs 0706 score comparison / Aozawa 0701 と 0706 のスコア比較

The two Aozawa tests are useful because they provide two reports for the same learner within five days.

Aozawa の2回のテストは、同じ学習者について5日以内に2件のレポートを提供しているため有用である。

Category	2026-07-01	2026-07-06	Observed change
Overall	A2 High	B1 High	up one reported overall band
Range	B1	B2 and above	up substantially
Accuracy	A2	B1	up
Fluency	B2 and above	B1	down
Interaction	A2	B1	up
Coherence	B1	B2 and above	up substantially
Phonology	B1	B1	unchanged

This pattern is not easy to interpret as a simple, stable proficiency estimate. Most categories moved upward, one moved downward, and one stayed unchanged over a very short interval.

The change may reflect some combination of:

- real performance variation between the two tests
- different task content
- different prompt difficulty
- greater familiarity with the test format
- different topic fit

このパターンは、単純で安定した熟達度推定として解釈することが難しい。非常に短い期間で、ほとんどのカテゴリーは上がり、1つは下がり、1つは変わらなかった。

この変化は、次の要因の組み合わせを反映している可能性がある。

- 2回のテスト間における実際のパフォーマンス変動
- 異なるタスク内容
- 異なるプロンプト難度
- テスト形式への慣れの増加
- トピックとの相性の違い
- 2回目の Part 5 における誤解の減少

- reduced misunderstanding in the second Part 5
- the observer's clarification in the second Part 5 preparation period
- normal measurement variation

The available evidence cannot separate these causes.

- 2 回目の Part 5 準備時間における観察者の説明

- 通常の測定上のばらつき

利用可能な根拠資料では、これらの原因を切り分けることはできない。

5.4 Limitations of the Available Evidence / 利用可能な根拠資料の限界

The 0701/0706 comparison is an informal repeated-test comparison, with different content and different test conditions.

It does show that the reported score profile can change substantially between two tests taken close together, under conditions that are not transparently explained by the report. That is a material limitation for organisational use, especially for pre/post testing or fine placement.

If a learner can move from "A2 High" to "B1 High" within five days, stakeholders need guidance on whether that change is:

- expected normal variation
- a meaningful proficiency change
- an effect of different test content
- an effect of test delivery conditions
- a scoring/classification effect

The public materials reviewed do not provide that guidance.

0701 と 0706 の比較は、内容とテスト条件が異なる非公式な反復テスト比較である。

ただし、近い時期に受けた 2 回のテストの間で、レポート上のスコアプロフィールが大きく変化し得ることは示している。また、その変化をレポートが透明に説明していない条件下で起きている。この点は、特に事前・事後テストや詳細なクラス分けなど、組織内利用にとって重要な限界である。

学習者が 5 日以内に「A2 High」から「B1 High」へ移動し得るなら、関係者はその変化が何を意味するのかについて指針を必要とする。

- 予想される通常のばらつき
- 意味のある熟達度変化
- 異なるテスト内容の影響
- テスト実施条件の影響
- 採点または分類の影響

確認した公開資料は、その指針を提供していない。

5.5 Part 5 and Reliability / Part 5 と信頼性

The two tests strengthen the earlier concern about Part 5. In 0701, task misunderstanding dominated the Communication Activity. In 0706, an external clarification occurred during preparation, and the re-

2 回のテストは、Part 5 に関する先の懸念を強める。0701 では、タスク誤解が Communication Activity を支配した。0706 では、準備中に外部からの説明が入り、回答は意図されたトピックにより合ったものになった。

sponse was more aligned with the intended topic.

This is important for reliability because it shows that score-relevant performance may depend heavily on whether the learner understands the scenario and role. The three reviewed score reports do not explain whether or how such comprehension problems are detected, discounted, or incorporated into Interaction, Coherence, or overall scoring.

これは信頼性にとって重要である。スコアに関するパフォーマンスが、学習者がシナリオと役割を理解しているかに大きく依存する可能性を示しているためである。確認した 3 件のスコアレポートは、このような理解上の問題が検出されるのか、割引かれるのか、あるいは Interaction、Coherence、総合採点に組み込まれるのかを説明していない。

6. Test Instructions and Language / テスト指示と使用言語

6.1 Language and Clarity of Instructions / 指示の言語と明確性

The test depends heavily on learners understanding short written or audio task instructions quickly. Several observed items were understandable but not ideally worded, and Part 5 created the clearest instruction risk. In Aozawa's 2026-07-01 test, he appears to have misunderstood the role and scenario across all four Part 5 prompts. In the 2026-07-06 test, the observer's clarification during preparation showed that the Part 5 setup could still require explanation.

このテストは、学習者が短い書面または音声によるタスク指示を迅速に理解することに大きく依存している。観察された複数の項目は理解可能ではあったが、必ずしも理想的な表現ではなく、Part 5 が最も明確な指示リスクを生んだ。Aozawa の 2026-07-01 のテストでは、Part 5 の 4 つすべてのプロンプトにわたって役割とシナリオを誤解していたように見える。2026-07-06 のテストでは、準備中の観察者による説明により、Part 5 の設定にはなお説明が必要になり得ることが示された。

6.2 Cognitive and Listening Demands / 認知的負荷とリスニング負荷

The test measures more than spoken output. Part 1 and Part 5 require audio-prompt comprehension under time pressure. Part 4 requires graph literacy and rapid selection of relevant visual information. These demands may be defensible for a business-English test, but they should be acknowledged because they can affect scores independently of speaking ability.

このテストは、発話出力だけを測定しているわけではない。Part 1 と Part 5 では、制限時間内で音声プロンプトを理解する必要がある。Part 4 では、グラフィテラシーと関連する視覚情報を迅速に選択する力が必要である。これらの要求はビジネス英語テストとしては正当化できるかもしれないが、スピーキング能力とは独立してスコアに影響し得るため、明示的に認識されるべきである。

6.3 Accessibility and Construct-Irrelevant Variance / アクセシビリティと測定概念外のばらつき

If the intended construct is English-only workplace task performance, then English-only instructions and audio-only prompts may be part of the construct. If the intended construct is spoken production or spoken interaction more narrowly, then unclear task setup, role confusion, audio comprehension load, graph literacy, and time pressure may introduce construct-irrelevant variance. The reviewed reports do

意図された測定概念が英語のみでの職場タスク遂行であるなら、英語のみの指示と音声のみのプロンプトは測定概念の一部である可能性がある。一方、意図された測定概念がより狭くスピーキング産出または口頭インタラクションであるなら、不明確なタスク設定、役割混乱、音声理解負荷、グラフィテラシー、時間制限は、測定概念とは無関係なばらつきをもたらす可能性がある。確認したレポートは、このような影響

not explain how such effects are detected or handled.

がどのように検出または処理されるかを説明していない。

7. Fairness and Accessibility / 公平性とアクセシビリティ

7.1 Topic Familiarity, Bias, and Access / トピック親近性、バイアス、アクセス

Observed strengths:

- standardised delivery
- short testing window
- familiar workplace-oriented domains
- reduced live-examiner variation

Observed concerns:

- workplace prompts may advantage learners with office or business experience
- Part 1 and Part 5 depend on audio-only prompt comprehension
- Part 4 adds graph-literacy and rapid visual-interpretation demands
- Part 5 role comprehension can materially affect performance
- English-only task setup may introduce construct-irrelevant difficulty if the intended construct is spoken production rather than English-only task comprehension

The available evidence does not support a strong judgment on:

- disability accommodations
- accent bias
- microphone or recording-quality effects
- speech-recognition bias
- technical failure rates

These areas remain unevaluated rather than satisfactory.

観察された強みは次のとおりである。

- 標準化された実施
- 短い受験時間
- 親しみのある職場志向の領域
- ライブ試験官によるばらつきの低減

観察された懸念は次のとおりである。

- 職場プロンプトは、オフィスまたはビジネス経験のある学習者に有利に働く可能性がある
- Part 1 と Part 5 は、音声のみのプロンプト理解に依存している
- Part 4 は、グラフィテラシーと迅速な視覚情報解釈の負荷を追加する
- Part 5 の役割理解は、パフォーマンスに実質的な影響を与え得る
- 意図された測定概念が英語のみのタスク理解ではなくスピーキング産出である場合、英語のみのタスク設定は測定概念とは無関係な難しさをもたらす可能性がある

利用可能な根拠資料では、次の点について強い判断はできない。

- 障害に関する配慮
- アクセントバイアス
- マイクまたは録音品質の影響
- 音声認識バイアス
- 技術的不具合の発生率

これらの領域は、満足できると判断されたのではなく、未評価のままである。

8. Practicality / 実用性

8.1 Cost, Scalability, Delivery, and Reporting Speed / コスト、拡張性、実施、レポート速度

PROGOS appears practically attractive:

- it is short
- it is standardised
- it does not require a live examiner
- reports are generated through an existing platform
- the captured public terms state that results are posted within five business days

That makes it scalable in delivery terms, especially compared with live examiner-based speaking tests. However, this review did not evaluate pricing, procurement burden, technical-support load, failure rates, or the real operational cost of retesting after technical problems.

Practicality should be separated from interpretive quality. A test can be operationally efficient and easy to use while still requiring caution for fine-grained or consequential decisions.

PROGOS は実務上魅力的に見える。

- 短時間である
- 標準化されている
- ライブ試験官を必要としない
- 既存のプラットフォームを通じてレポートが生成される
- 保存した公開規約では、結果は5 営業日以内に掲載されるとされている

このため、特にライブ試験官によるスピーキングテストと比べると、実施面で拡張しやすい。ただし、本レビューでは、価格、調達負担、技術サポート負荷、不具合発生率、技術的問題後の再受験にかかる実際の運用コストは評価していない。

実用性は、解釈の質と区別すべきである。テストは運用上効率的で使いやすい一方で、詳細な判断または影響の大きい判断には慎重さを要する場合がある。

9. Evaluation of the Score Reports / スコアレポートの評価

9.1 Report Structure and Descriptor-Alignment Scope / レポート構成とディスクリプター照合の範囲

The Overall Assessment summary in each report is not itself a CEFR competence in the descriptor workbook. It should not be treated as a direct CEFR descriptor match.

Because PROGOS public materials do not clearly separate CEFR and CEFR-J use, this report treats CEFR and CEFR-J as parallel descriptor-alignment checks. Neither descriptor set is treated as the default or higher-priority source.

CEFR workbook same-competence matching applies only to the six individual score-report categories:

- Range
- Accuracy
- Fluency
- Interaction
- Coherence
- Phonology

CEFR-J matching is different because the CEFR-J descriptor PDFs reviewed for this report are organised mainly as spoken-interaction and spoken-production can-do descriptors. They can provide activity-level matches, but they do not provide separate same-category scales for all six score-report categories.

For the CEFR-J comparison, "A2 High" is checked mainly against upper-A2 descriptors such as "A2.2"; "B1 High" is checked mainly against upper-B1 descriptors such as "B1.2", while also noting B1.1 overlap where the wording is interactional. "B2 and above" remains less precise because the PROGOS label does not state whether the intended CEFR-J comparator is "B2.1", "B2.2", "C1", or "C2".

確認した 3 件のスコアレポートは、学習者向けに安定した構成を持つ。すなわち、CEFR 形式の総合結果、指標別評価の下 の 6 つのカテゴリー別評価、Overall Assessment コメント、カテゴリー別コメント、アドバイス、例文である。この構成は読みやすく、学習者の動機づけにつながる可能性があるが、報告された判断を根拠となる回答証拠から切り離している。本レビューで確認したレポートには、学習者の回答抜粋、タスク別のパフォーマンス記録、スコア算出方法、重みづけ、測定誤差の指針、重大なタスク誤解の表示は含まれていない。

各レポートの Overall Assessment 要約は、ディスクリプターワークブックにおける CEFR コンピテンスそのものではない。直接的な CEFR ディスクリプター一致として扱うべきではない。

PROGOS の公開資料では CEFR と CEFR-J の使用を明確に区別していないため、本報告書では CEFR と CEFR-J を並行するディスクリプター照合として扱う。どちらのディスクリプターセットも、既定または優先度の高い資料としては扱わない。

CEFR ワークブックの同一コンピテンス照合は、スコアレポートの 6 つの個別カテゴリーにのみ適用する。

- 言語範囲
- 正確さ
- 流暢さ
- インタラクション
- 一貫性
- 音韻

CEFR-J 照合はこれとは異なる。確認した CEFR-J ディスクリプターPDF は、主にスピ

The three reviewed score reports have a stable learner-facing structure: an overall CEFR-style result, six category-level ratings under 指標別評価, an Overall Assessment comment, category-level comments, advice, and example language. That structure is easy to read and may be motivating for learners, but it separates the reported judgments from the underlying response evidence. The reports reviewed here do not include learner response excerpts, task-by-task performance notes, score derivation, weighting, measurement-error guidance, or a flag for major task misunderstandings.

ーキング・インタラクションとスピーキング・プロダクションの can-do ディスクリプターとして整理されているためである。活動レベルの一致は示せるが、スコアレポートの 6 カテゴリーすべてについて、独立した同一カテゴリーのスケールを提供しているわけではない。

CEFR-J 比較では、「A2 High」は主に「A2.2」など上位 A2 のディスクリプターと照合し、「B1 High」は主に「B1.2」など上位 B1 のディスクリプターと照合する。ただし、表現がインタラクション的である場合は B1.1 との重なりも指摘する。「B2 and above」は、意図された CEFR-J 上の比較対象が「B2.1」、「B2.2」、「C1」、「C2」のいずれであるかを PROGOS のラベルが示していないため、精度が低いままである。

9.2 Category Scores and CEFR Workbook Comparison / カテゴリースコアと CEFR ワークブックの比較

9.2.1 Aozawa 0701 CEFR Comparison / Aozawa 0701 CEFR 比較

The 2026-07-01 Aozawa report gave:

2026-07-01 の Aozawa レポートでは、次の結果が示された。

Category	Reported level	Same-competence same-level CEFR match?	Judgment
Range	B1	No	PROGOS wording is stronger than official B1 General linguistic range.
Accuracy	A2	Yes	Acceptable paraphrase of A2 Grammatical accuracy.
Fluency	B2 and above	Yes	Acceptable match to the selected Fluency descriptor, though the open-ended label is not explained.
Interaction	A2	No	Wording is closer to A2+ than A2, and the task does not directly support conversation leadership/following.
Coherence	B1	Yes	Close paraphrase of B1 Coherence and cohesion.

Phonology	B1	Yes	Close match to B1 Overall phonological control.
------------------	----	-----	---

9.2.2 Aozawa 0706 CEFR Comparison / Aozawa 0706 CEFR 比較

The 2026-07-06 Aozawa report gave:

2026-07-06 の Aozawa レポートでは、次の結果が示された。

Category	Reported level	Same-competence same-level CEFR match?	Judgment
Range	B2 and above	No	Using B2+ as the proxy, the report wording is closer to B2 General linguistic range than B2+.
Accuracy	B1	No	The reference to noticeable first-language influence is closer to B1+ Grammatical accuracy than B1.
Fluency	B1	Yes	Acceptable match to B1 Fluency.
Interaction	B1	Yes	Close wording match to B1 Overall oral interaction.
Coherence	B2 and above	No	Using B2+ as the proxy, the phrase "limited number" is closer to B2 Coherence and cohesion.
Phonology	B1	Yes	Close match to B1 Overall phonological control.

The 0706 findings add a new problem. Several report comments align more closely with a neighbouring CEFR descriptor than with the reported level/proxy level. This does not prove the score is wrong, but it weakens the learner-facing interpretation that the category comment is a precise explanation of the reported level.

0706 の所見は、新たな問題を追加する。複数のレポートコメントは、報告レベルまたは代理レベルよりも隣接する CEFR ディスクリプターにより近く一致している。これはスコアが誤っていることを証明するものではないが、カテゴリーコメントが報告レベルを正確に説明しているという学習者向けの解釈を弱める。

9.3 CEFR-J Descriptor Comparison / CEFR-J ディスクリプター比較

The CEFR-J check gives a parallel view rather than replacing the CEFR workbook check.

CEFR-J チェックは、CEFR ワークブックチェックを置き換えるものではなく、並行した見方を与えるものである。

Re- port	PROGOS category	Re- ported level	Closest CEFR-J de- scriptor area	CEFR-J judgment
2026-07-01	Overall Assessment	A2 High	Spoken interaction / spoken production, everyday topics and simple language	Partial match. The wording is compatible with the A2 range, but it blends production and interaction.
2026-07-01	Range	B1	Spoken interaction on a wide range of topics	Mismatch if compared to CEFR-J B1. The wording is closer to higher-level CEFR-J interaction language.
2026-07-01	Accuracy	A2	None	No appropriate CEFR-J descriptor-set match; the CEFR-J descriptor PDF does not provide a grammatical-accuracy scale.
2026-07-01	Fluency	B2 and above	Spoken production / interaction with fluent extended speech	Partial match only; CEFR-J embeds fluency in activity descriptors rather than a separate Fluency scale.
2026-07-01	Interaction	A2	Spoken interaction in predictable everyday situations and familiar topics	Partial to close match. A2.2 and B1.1 descriptors overlap with the wording, but the report's "other person leads" condition is not explicit in CEFR-J.
2026-07-01	Coherence	B1	Spoken production with joined longer contributions	Weak partial match only; CEFR-J does not provide a separate coherence/cohesion scale.
2026-07-01	Phonology	B1	None	No appropriate CEFR-J descriptor-set match; the CEFR-J descriptor PDF does not provide a phonology scale.
2026-07-06	Overall Assessment	B1 High	Spoken production about social situations plus social conversation	Strong match to CEFR-J B1.2 spoken production with B1.1 spoken-interaction overlap.
2026-07-06	Range	B2 and above	Spoken interaction / production on wider topics with clear expression	Partial match. CEFR-J supports a higher speaking-activity interpretation but not a same-category Range match.
2026-07-06	Accuracy	B1	None	No appropriate CEFR-J descriptor-set match; the CEFR-J

				descriptor PDF does not provide a grammatical-accuracy scale.
2026-07-06	Fluency	B1	Spoken production with longer contributions or some fluency	Partial match only; CEFR-J does not include the pause/repair wording as a separate Fluency scale.
2026-07-06	Interaction	B1	Spoken interaction, familiar topics, information exchange, wide range of simple English	Close match to CEFR-J B1.1 spoken interaction.
2026-07-06	Coherence	B2 and above	None directly	No appropriate same-category CEFR-J match; the limited-linking-expression wording is not represented as a B2-and-above CEFR-J speaking descriptor.
2026-07-06	Phonology	B1	None	No appropriate CEFR-J descriptor-set match; the CEFR-J descriptor PDF does not provide a phonology scale.

This adds nuance to the CEFR workbook findings. Some activity-style PROGOS comments have clearer CEFR-J parallels, especially the 2026-07-06 Overall Assessment and the 2026-07-06 Interaction comment. However, CEFR-J does not resolve alignment for score-report categories that its descriptor set does not separately define, especially Accuracy and Phonology.

これは CEFR ワークブックの所見にニュアンスを加える。活動形式の PROGOS コメントの一部は、特に 2026-07-06 の Overall Assessment と 2026-07-06 の Interaction コメントにおいて、CEFR-J との対応がより明確である。しかし、CEFR-J は、特に Accuracy と Phonology のように、そのディスクリプターセットが独立して定義していないスコアレポートカテゴリーについては、照合上の問題を解決しない。

9.4 Overall Assessment Comments / Overall Assessment コメント

The 0701 Overall Assessment is not a useful synthesis of overall speaking performance. It mainly concerns simple words, phrases, sentences, and basic vocabulary/expressions. It omits substantive information about Accuracy, Fluency, Coherence, and Phonology and gives only a limited interactional statement.

0701 の Overall Assessment は、総合的なスピーキングパフォーマンスの有用な統合ではない。主に簡単な語、句、文、基本的な語彙・表現に関するものである。Accuracy、Fluency、Coherence、Phonology に関する実質的な情報を省略し、Interaction についても限定的な記述しか示していない。

The 0706 Overall Assessment is more performance-like because it refers to presentation and social conversation. It says the learner can give a reasonably smooth presentation about social issues of interest and continue a social conversation with detailed explanations. However, this still overreaches the observed evidence in two ways:

- the observed Part 5 is not a live social conversation
- the report does not show how the statement was derived from the learner's actual responses

Both summaries use unqualified "You can" statements. They present broad ability inferences as facts rather than as interpretations based on a limited task sample.

0706 の Overall Assessment は、プレゼンテーションと日常的な会話に言及しているため、よりパフォーマンスに近い。しかし、関心のある社会問題についてある程度滑らかにプレゼンテーションでき、詳細な説明を交えながら日常的な会話を続けられると述べている点は、なお観察された根拠を次の2点で超えている。

- 観察された Part 5 はライブの日常会話ではない
- レポートは、その記述が学習者の実際の回答からどのように導かれたかを示していない

どちらの要約も、限定条件のない「You can」記述を用いている。限られたタスクサンプルに基づく解釈ではなく、広い能力推論を事実として提示している。

9.5 Diagnostic Usefulness, Individualisation, and Templating / 診断上の有用性、個別化、テンプレート性

The reports are clear and potentially motivating. They are weak as individual diagnostic reports because they do not:

- quote the learner's own responses
- identify task-specific successes or errors
- explain why a rating was awarded
- connect advice to observed performance
- flag major scenario or role misunderstandings

The comparison among Aozawa 0701, Aozawa 0706, and Saki 0630 supports a category-by-level templating interpretation. When the same category and level occur, the comment/advice/example content appears substantively reusable. When the level changes, the text changes. This does not invalidate the scores, but it means the learner-facing feedback should be treated

レポートは明確で、学習者の動機づけにつながる可能性がある。しかし、次の点がないため、個別診断レポートとしては弱い。

- 学習者本人の回答を引用すること
- タスク固有の成功点または誤りを特定すること
- なぜその評価が与えられたかを説明すること
- アドバイスを観察されたパフォーマンスに結びつけること
- 重大なシナリオまたは役割の誤解を示すこと

Aozawa 0701、Aozawa 0706、Saki 0630 の比較は、カテゴリー別・レベル別のテンプレート解釈を支持する。同じカテゴリーとレベルが現れる場合、コメント、アドバイス、例文の内容は実質的に再利用可能に見える。レベルが変わると、テキストも変わる。これはスコアを無効にするものではないが、学習者向けフィードバックは個別診

as level-based guidance rather than individual diagnosis.

Examples of advice that is not demonstrably anchored to observed performance include:

- practising "I wish"
- using "Hmm" to express doubt or disagreement
- opening opinions with "In my opinion"
- using "basically" to avoid silence
- practising "hence"
- watching or repeating public speeches

These may be useful study suggestions, but the reports do not show that they were selected because of anything the learner actually did.

断ではなく、レベルに基づく指針として扱うべきであることを意味する。

観察されたパフォーマンスに明確に基づいているとは示されていないアドバイスの例には、次のものがある。

- 「I wish」の練習
 - 疑念または反対を表すために「Hmm」を使うこと
 - 「In my opinion」で意見を切り出すこと
 - 沈黙を避けるために「basically」を使うこと
 - 「hence」の練習
 - 公開スピーチを視聴または繰り返すこと
- これらは有用な学習提案かもしれないが、レポートは、それらが学習者の実際の行動に基づいて選ばれたことを示していない。

9.6 Transparency of Score Interpretation / スコア解釈の透明性

The reports do not explain how the five task parts contribute to the six category ratings, how the category ratings are aggregated, or how the overall level is derived. This matters because the observed profiles do not make the aggregation rule obvious: Aozawa's 2026-07-01 report and Saki's 2026-06-30 report both show "A2 High" overall results despite different category profiles, and Aozawa's 2026-07-06 report shows a changed overall result without explaining whether the change is meaningful, expected variation, an effect of different test content, an effect of test conditions, or a scoring effect.

The finer labels such as "A2 High", "B1 High", and "B2 and above" make the report more granular than a simple six-band CEFR output, but the reviewed materials do not define the cut scores, stability, measurement error, or minimum mean-

レポートは、5つのタスクパートが6つのカテゴリー評価にどのように寄与するか、カテゴリー評価がどのように集計されるか、総合レベルがどのように導かれるかを説明していない。この点は重要である。観察されたプロフィールからは集計規則が明らかではない。Aozawa の 2026-07-01 レポートと Saki の 2026-06-30 レポートは、カテゴリー別プロフィールが異なるにもかかわらず、どちらも総合結果が「A2 High」であり、Aozawa の 2026-07-06 レポートは、変化が意味のあるものなのか、予想されるばらつきなのか、異なるテスト内容の影響なのか、テスト条件の影響なのか、採点上の影響なのかを説明しないまま、総合結果の変化を示している。

「A2 High」、「B1 High」、「B2 and above」などの細かいラベルにより、レポートは単純な6段階 CEFR 出力よりも細分化されている。しかし、確認した資料は、これらのラベルに関連するカットスコア、安

ingful change associated with those labels. For organisational use, that absence is a practical transparency problem: stakeholders can see that a label changed, but not how confidently that change should be interpreted.

定性、測定誤差、または意味のある最小変化を定義していない。組織内利用において、この欠如は実務上の透明性の問題である。関係者はラベルが変わったことは見えるが、その変化をどの程度確信して解釈すべきかは分からない。

10. Legal and Ethical Considerations / 法務上および倫理上の考慮事項

This section is descriptive, not legal advice.

The public pages captured on 2026-07-03 are materially more informative than the older corporate privacy-management page. They identify voice data, possible monitoring-camera images, employer or service-provider disclosure in applicable contracts, outsourcing and re-outsourcing, international handling including Japan and the Philippines, and data-subject rights.

本セクションは記述的なものであり、法的助言ではない。

2026-07-03 に保存した公開ページは、より古い企業プライバシー管理ページよりも実質的に多くの情報を提供している。これらは、音声データ、監視カメラ画像の可能性、該当契約における雇用主またはサービス提供者への開示、委託および再委託、日本およびフィリピンを含む国際的な取扱い、データ主体の権利を特定している。

10.1 Privacy, Terms of Use, and Voice Recordings / プライバシー、利用規約、音声録音

The captured public pages state or indicate that:

- PROGOS uses automated voice delivery
- scores are based on the company's own evaluation criteria
- results are posted within five business days
- inquiries about test results or test content will not be answered
- no representation or warranty is made regarding the completeness or accuracy of results
- audio is recorded during the test
- monitored tests may involve PC-camera image data
- personal data include name, email address, voice data, IP address, cookie information, and website access history
- personal data may be handled in multiple countries, including Japan and the Philippines

保存した公開ページは、次のことを述べている、または示している。

- PROGOS は自動音声による出題を使用する
- スコアは同社独自の評価基準に基づく
- 結果は 5 営業日以内に掲載される
- テスト結果またはテスト内容に関する問い合わせには回答しない
- 結果の完全性または正確性について表明または保証は行われない
- テスト中に音声録音される
- 監視付きテストでは PC カメラ画像データが関係する場合がある
- 個人データには、氏名、メールアドレス、音声データ、IP アドレス、Cookie 情報、ウェブサイトアクセス履歴が含まれる
- 個人データは、日本およびフィリピンを含む複数の国で取り扱われる可能性がある
- 委託および再委託が認められている
- 匿名化された統計データは、将来の商品・サービス開発および営業活動に使用される可能性がある

- outsourcing and re-outsourcing are permitted
- anonymised statistical data may be used for future product/service development and sales activity
- personal data are retained unless deletion is requested, and deletion after request is stated to occur within one month
- technical interruptions have different rules depending on monitored or unmonitored test delivery
- re-examination after communication problems or applicant-attributable recording defects may require a new application and fee
- recording test content, taking screenshots, and disclosing questions are prohibited by the test-taker terms
- content and terms may be changed with notice
- Japanese governs where versions conflict
- 個人データは削除要請がない限り保持され、要請後の削除は1か月以内に行われるとされている
- 技術的中断については、監視付きまたは監視なしのテスト実施によって異なる規則がある
- 通信上の問題または申込者に起因する録音不備の後の再受験には、新たな申込みと費用が必要になる場合がある
- テスト内容の録音、スクリーンショット撮影、問題の開示は受験者規約で禁止されている
- 内容および規約は通知により変更される場合がある
- 各版が矛盾する場合、日本語版が優先される

10.2 AI Governance and Transparency Gaps / AI ガバナンスと透明性の不足

The public pages reviewed do not provide:

- psychometric validation evidence
- a scoring manual
- task-to-score mappings
- score weighting or aggregation rules
- evidence about score stability across repeated tests
- evidence that different test versions are equivalent
- subscore reliability evidence
- classification-consistency evidence
- measurement-error information
- an explicit routine retention period for voice data absent a deletion request
- an explicit routine retention period for monitoring images absent a deletion request

確認した公開ページは、次のものを提供していない。

- 心理測定上の妥当性検証資料
- 採点マニュアル
- タスクとスコアの対応表
- スコアの重みづけまたは集計規則
- 反復受験におけるスコア安定性に関する根拠
- 異なるテストバージョンが等価であることを示す根拠
- サブスコアの信頼性に関する根拠
- 分類一貫性に関する根拠
- 測定誤差情報
- 削除要請がない場合の音声データの明示的な通常保持期間

- a clear score-appeal or human-review procedure
- AI-model governance detail for the scoring process

For assessment governance, those omissions matter more than the presence of general corporate privacy language.

- 削除要請がない場合の監視画像の明示的な通常保持期間
- 明確なスコア不服申立てまたは人間による確認手続き
- 採点プロセスに関する AI モデルガバナンスの詳細

評価ガバナンス上、これらの欠落は一般的な企業プライバシー文言の存在よりも重要である。

11. Suitability for the Organisation's Purposes / 組織の目的に対する適合性

This section translates the assessment findings into the organisation's likely operational uses: class allocation, pre/post testing, course design, teacher selection, and individual learner support.

本セクションでは、評価上の所見を、クラス割り当て、事前・事後テスト、コース設計、講師選定、個別学習者支援といった組織の想定される運用上の利用に置き換えて説明する。

Use case	Suitability	Rationale
Broad external benchmarking	Suitable as supplementary evidence	The test is standardised and gives broad CEFR-style output.
Class allocation / broad initial placement support	Supplementary only	It may help with coarse grouping, but should not replace local evidence.
Fine-grained placement	Not recommended as primary evidence	Subscore reliability, measurement error, equivalence between test versions, and aggregation rules are unavailable.
Short-cycle pre/post progress measurement	Not recommended as primary evidence	The 0701/0706 comparison shows large short-interval movement without evidence explaining meaningful change or normal variation.
Course design	Limited usefulness	The reports do not provide enough performance-specific diagnostic detail.
Teacher assignment	Limited usefulness	The output is not granular enough to guide teacher matching by specific learner needs.
Individual diagnostic assessment	Limited usefulness	Feedback appears category-by-level based and is not anchored to the learner's own responses.

11.1 Pre/Post Testing and Score-Change Interpretation / 事前・事後テストとスコア変化の解釈

The 0706 result should be used as evidence that repeated PROGOS tests can produce materially different profiles over a short interval. It should not be described as a formal reliability study because:

- the test content differed

0706の結果は、PROGOSの反復受験が短期間でも実質的に異なるプロフィールを生み得ることを示す根拠として用いるべきである。次の理由により、正式な信頼性研究として説明すべきではない。

- テスト内容が異なっていた

- the Part 5 topic differed
- the Part 3 and Part 4 prompts differed
- the observer clarified the scenario during the 0706 Part 5 preparation period
- no official measurement-error information or test-version equivalence information is available

The correct conclusion is not "PROGOS is unreliable". The correct conclusion is:

> Reliability and score-change interpretation are not established from the available evidence, and the observed two-test comparison shows enough short-interval movement and sensitivity to test conditions to make primary use for fine placement or short-cycle progress measurement risky.

- Part 5 のトピックが異なっていた
- Part 3 と Part 4 のプロンプトが異なっていた
- 0706 の Part 5 準備時間中に観察者がシナリオを説明した
- 公式の測定誤差情報またはテストバージョン等価性情報が利用できない

正しい結論は「PROGOS は信頼性がない」ではない。正しい結論は次のとおりである。

> 利用可能な根拠資料からは信頼性およびスコア変化の解釈は確立されておらず、観察された 2 回のテスト比較は、短期間での十分な変動とテスト条件への感度を示しているため、詳細なクラス分けまたは短期間の進捗測定に主要利用することはリスクが高い。

12. Conclusions and Recommendations / 結論と提言

12.1 Summary of Findings / 所見の要約

PROGOS is strongest as a practical, standardised, automated speaking assessment for broad external benchmarking. The observed task mix gives real evidence of spoken production, short prompted response, discourse organisation, graph explanation, and pronunciation-related performance.

Its main weakness is interpretive. The observed test evidence is stronger for speaking production than for live interaction, yet Interaction appears as one of the six category-level ratings in the reviewed score reports. Part 4 also requires mediation of visual information, but that mediation performance is not separately reported in the reviewed score reports. The reports are readable, but their comments and study advice appear largely level-based and are not tied to specific response evidence. The first Aozawa report did not identify a major Part 5 role misunderstanding. The second Aozawa test improved the available evidence base but also showed that score profiles can change substantially over a short interval when content and test conditions are not equivalent.

The public legal pages clarify data handling and operational policies, but they do not fill the core assessment-evidence gap. The available materials do not provide the psychometric, reliability, scoring-method, test-version equivalence, measurement-error, and governance documentation needed to support stronger uses.

For progress measurement, the problem should be stated precisely. PROGOS may detect movement between its reported bands, including finer labels such as "A2

PROGOS の最大の強みは、広範囲の外部ベンチマークとして実用的で、標準化され、自動化されたスピーキング評価である点にある。観察されたタスクの組み合わせは、スピーキング産出、短いプロンプト応答、談話構成、グラフ説明、発音関連パフォーマンスについて実際の根拠を与える。

主な弱点は解釈にある。観察されたテスト根拠はライブインタラクションよりもスピーキング産出に強いが、Interaction は確認したスコアレポートにおいて 6 つのカテゴリ別評価の一つとして表示されている。Part 4 も視覚情報の媒介を必要とするが、その媒介パフォーマンスは確認したスコアレポートでは独立して報告されていない。レポートは読みやすいが、そのコメントと学習アドバイスは主としてレベル別のものであり、具体的な回答根拠に結びついていないように見える。Aozawa の 1 回目のレポートは、Part 5 における重大な役割誤解を特定していなかった。Aozawa の 2 回目のテストは利用可能な根拠資料を改善したが、内容とテスト条件が等価でない場合、スコアプロフィールが短期間で大きく変化し得ることも示した。

公開法務ページは、データ取扱いと運用方針を明確にしているが、評価上の中心的な根拠不足を埋めるものではない。利用可能な資料は、より強い利用を支えるために必要な、心理測定、信頼性、採点方法、テストバージョン等価性、測定誤差、ガバナンスに関する文書を提供していない。

進捗測定については、問題を正確に述べる必要がある。PROGOS は「A2 High」や「B1 High」などの細かいラベルを含め、報告バンド間の移動を検出できるかもしれない。しかし、公開資料は、どの程度の移動が意味のあるものか、その分類がどの程度安定しているか、通常どの程度のばらつき

High" and "B1 High", but the public materials do not explain how much movement is meaningful, how stable those classifications are, or how much normal variation should be expected. The Aozawa 0701/0706 comparison makes that limitation concrete.

が予想されるかを説明していない。Aozawa 0701/0706 の比較は、この限界を具体的に示している。

12.2 Limitations / 限界

This report has clear limits:

- Only two full observed tests for the same learner were available.
- The two Aozawa tests were not a controlled reliability study.
- The second test included external clarification during Part 5 preparation.
- Only three score reports were available for report-template comparison.
- No internal technical or psychometric documents were available.
- No vendor clarification process was conducted from within this evidence set.
- CEFR-J descriptor resources were available as a parallel alignment source. The CEFR-J report-comment matching remains limited to the descriptor PDFs reviewed for this report; it does not use the less relevant grammar-profile or wordlist files.
- The report evaluates the available evidence set; it does not establish how PROGOS performs across a large learner population.

本報告書には明確な限界がある。

- 同じ学習者について観察できた完全なテストは2件のみであった。
- Aozawa の2回のテストは、統制された信頼性研究ではなかった。
- 2回目のテストでは、Part 5の準備中に外部からの説明が含まれていた。
- レポートテンプレート比較に利用できたスコアレポートは3件のみであった。
- 内部の技術文書または心理測定文書は利用できなかった。
- この根拠資料の範囲内では、ベンダーへの確認プロセスは実施していない。
- CEFR-J ディスクリプター資料は、並行する照合資料として利用できた。CEFR-J のレポートコメント照合は、本報告書で確認したディスクリプターPDFに限定され、関連性の低い文法プロファイルまたはワードリストファイルは使用していない。
- 本報告書は利用可能な根拠資料を評価するものであり、大規模な学習者集団において PROGOS がどのように機能するかを確立するものではない。

12.3 Recommendations / 提言

1. Treat PROGOS as supplementary external evidence, not as a replacement for the organisation's existing assessment system.
2. Do not use the current evidence base alone to justify primary use for fine

1. PROGOS は、組織の既存評価システムの代替ではなく、補助的な外部根拠として扱う。
2. 現在の根拠資料だけをもって、詳細なクラス分け、短期間の進捗測定、コース設

placement, short-cycle progress measurement, course design, teacher assignment, or individual diagnostic planning.

3. If broader use is being considered, request from PROGOS:

- validation evidence
 - reliability evidence
 - evidence that different test versions are equivalent
 - measurement-error or minimum-detectable-change guidance
 - subscore interpretation guidance
 - score-review and human-review procedures
 - task-to-score mapping information
 - explanation of how category scores and overall levels are derived
4. If local adoption is still of interest, run a small internal validation study comparing PROGOS against the organisation's current assessment on shared learners and shared decisions.
5. For any local repeat-testing pilot, control the test conditions more tightly than the 0701/0706 evidence set:
- no external clarification during the test
 - document whether test content is identical or equivalent
 - record time between tests
 - compare PROGOS score changes with independent human ratings
 - document whether observed changes are large enough to affect actual placement decisions

計、講師割り当て、個別診断計画への主要利用を正当化しない。

3. より広い利用を検討する場合は、PROGOS に次の資料を求める。

- 妥当性検証資料
- 信頼性資料
- 異なるテストバージョンが等価であることを示す根拠
- 測定誤差または検出可能な最小変化に関する指針
- サブスコア解釈の指針
- スコア確認および人間による確認手続き
- タスクとスコアの対応情報
- カテゴリースコアと総合レベルがどのように算出されるかの説明

4. 内部導入に引き続き関心がある場合は、共通の学習者と共通の判断について、PROGOS を組織の現在の評価と比較する小規模な内部妥当性検証を実施する。

5. 内部で反復テストのパイロットを行う場合は、0701/0706 の根拠資料よりも厳密にテスト条件を統制する。

- テスト中に外部から説明を行わない
- テスト内容が同一または等価であることを記録する
- テスト間の期間を記録する
- PROGOS のスコア変化を独立した人間による評価と比較する
- 観察された変化が実際のクラス分け判断に影響するほど大きいかを記録する